

Documentation Formelle de Gouvernance des Données

Laboratoire GoodAir - TotalGreen

Version : 1.0

Date : Janvier 2025

Responsable : Équipe Data Engineering

Validation : Direction R&D TotalGreen

Table des Matières

1. Introduction et Objectifs
 2. Référentiel des Données
 3. Critères de Sélection et Validation
 4. Standards de Qualité
 5. Procédures de Sécurité et RGPD
 6. Cycle de Vie des Données
 7. Contrôles Qualité et Alertes
 8. Rôles et Responsabilités
-

1. Introduction et Objectifs

1.1 Contexte

Le laboratoire GoodAir, filiale de TotalGreen, a pour mission d'analyser la qualité de l'air et les conditions météorologiques en France pour :

- Proposer des recommandations à la population
- Étudier les conséquences du changement climatique
- Déterminer des seuils d'alerte
- Développer des plateformes de sensibilisation

1.2 Objectifs de la Gouvernance

- **Cohérence** : Assurer la mise à disposition de données cohérentes aux équipes de recherche
- **Fiabilité** : Garantir la qualité, l'exactitude et la traçabilité des données
- **Conformité** : Respecter les obligations légales (RGPD, sécurité)
- **Efficacité** : Optimiser l'exploitation des données par les différents métiers

2. Référentiel des Données

2.1 Sources de Données Validées

2.1.1 Données Météorologiques

Source : OpenWeatherMap API

URL : <https://openweathermap.org/api>

Type : Données temps réel

Fréquence : Toutes les heures

Données collectées :

Donnée	Type	Champ API	Format	Transformation
Température	Float	main.temp	Kelvin	Conversion °C
Température ressentie	Float	main.feels_like	Kelvin	Conversion °C
Pression atmosphérique	Integer	main.pressure	hPa	Aucune
Humidité	Integer	main.humidity	%	Validation 0-100%
Vitesse du vent	Float	wind.speed	m/s	Validation > 0
Direction du vent	Integer	wind.deg	Degrés	Validation 0-360°
Visibilité	Integer	visibility	Mètres	Validation > 0
Couverture nuageuse	Integer	clouds.all	%	Validation 0-100%

2.1.2 Données Qualité de l'Air

Source : AQICN (World Air Quality Index)

URL : <https://aqicn.org/json-api/doc/>

Type : Données temps réel

Fréquence : Toutes les heures

Données collectées :

Donnée	Type	Champ API	Format	Transformation
AQI Global	Integer	data.aqi	Index 0-500	Validation plage
Polluant dominant	String	data.dominentpol	Code	Mapping lisible
PM2.5	Float	data.iaqi.pm25.v	µg/m ³	Validation > 0

Donnée	Type	Champ API	Format	Transformation
PM10	Float	data.iaqi.pm10.v	µg/m ³	Validation > 0
Ozone (O3)	Float	data.iaqi.o3.v	µg/m ³	Validation > 0
Dioxyde d'azote (NO2)	Float	data.iaqi.no2.v	µg/m ³	Validation > 0

2.2 Périmètre Géographique

Villes couvertes : 12 principales villes françaises

- Paris, Marseille, Lyon, Toulouse, Nice, Nantes
- Strasbourg, Montpellier, Bordeaux, Lille, Rennes, Le Havre

3. Critères de Sélection et Validation

3.1 Critères de Sélection des Sources

- ✓ **Fiabilité** : Sources officielles ou certifiées
- ✓ **Disponibilité** : API accessible 24h/24
- ✓ **Fraîcheur** : Données mises à jour < 1 heure
- ✓ **Complétude** : Couverture géographique suffisante
- ✓ **Gratuité** : Compatible avec les contraintes budgétaires

3.2 Critères de Validation des Données

- ✓ **Plausibilité** : Valeurs dans les plages attendues
- ✓ **Cohérence** : Absence de contradictions internes
- ✓ **Complétude** : Taux de valeurs manquantes < 5%
- ✓ **Fraîcheur** : Horodatage récent (< 2 heures)

4. Standards de Qualité

4.1 Plages de Valeurs Acceptables

Paramètre	Minimum	Maximum	Unité
Température	-50	+60	°C
Humidité	0	100	%
Pression	900	1100	hPa

Paramètre	Minimum	Maximum	Unité
-----------	---------	---------	-------

Vitesse vent	0	200	m/s
AQI	0	500	Index
PM2.5/PM10	0	1000	µg/m ³

4.2 Indicateurs de Qualité

- **Score de Complétude** : (Cellules remplies / Total cellules) × 100
- **Score de Cohérence** : 100 - (Erreurs × 10)
- **Score de Fraîcheur** : % données < 2h
- **Score de Plausibilité** : 100 - (Valeurs aberrantes × 15)

4.3 Seuils d'Alerte Qualité

- **Excellent** : Score global ≥ 90%
- **Acceptable** : Score global 70-89%
- **Critique** : Score global < 70%

5. Procédures de Sécurité et RGPD

5.1 Classification des Données

Niveau de sensibilité : PUBLIC

Justification : Données météorologiques et environnementales publiques

5.2 Mesures de Sécurité Techniques

-  **Chiffrement** : Communications HTTPS/TLS obligatoires
-  **Authentification** : Accès contrôlé aux dashboards
-  **Logs d'audit** : Traçabilité des accès et modifications
-  **Sauvegarde** : Rétention 2 ans maximum

5.3 Conformité RGPD

Base légale : Intérêt légitime (recherche scientifique)

Données personnelles : AUCUNE collectée

Géolocalisation : Niveau ville uniquement (non nominative)

Conservation : 24 mois maximum

Droits des personnes : Information transparente sur les traitements

5.4 Transferts Internationaux

✗ **Interdiction** : Stockage hors UE strictement interdit

✓ **Localisation** : Serveurs France/UE exclusivement

6. Cycle de Vie des Données

6.1 Phase de Collecte

1. **Extraction** via APIs toutes les heures
2. **Validation** automatique temps réel
3. **Stockage** temporaire en Data Lake (MinIO)

6.2 Phase de Transformation

1. **Nettoyage** : Suppression valeurs aberrantes
2. **Enrichissement** : Calcul d'indices dérivés
3. **Validation** : Contrôles qualité automatisés

6.3 Phase de Stockage

1. **Data Lake** (MinIO) : Données brutes 6 mois
2. **Data Warehouse** (PostgreSQL) : Données structurées 2 ans
3. **Cache** : Données fréquentes en mémoire

6.4 Phase d'Archivage/Suppression

- **Données brutes** : Suppression automatique après 6 mois
 - **Données agrégées** : Conservation 2 ans puis suppression
 - **Logs d'audit** : Conservation 1 an
-

7. Contrôles Qualité et Alertes

7.1 Contrôles Automatisés

- **Fréquence** : À chaque traitement (hourly)
- **Dimensions** : Complétude, Cohérence, Fraîcheur, Plausibilité
- **Outils** : Module data_quality.py développé en interne

7.2 Système d'Alertes

Déclencheurs :

- Score qualité < 80%
- Données manquantes > 24h
- Erreurs API > 3 consécutives

Notifications :

-  Email équipe technique
-  Alerte dashboard temps réel
-  Log détaillé pour investigation

7.3 Rapports de Qualité

- **Quotidien** : Dashboard monitoring automatique
 - **Hebdomadaire** : Rapport synthèse pour direction R&D
 - **Mensuel** : Analyse tendances et améliorations
-

8. Rôles et Responsabilités

8.1 Data Engineer (Responsable Technique)

- **Responsabilités :**
 - Maintenance des pipelines ETL
 - Surveillance qualité des données
 - Résolution incidents techniques
 - Évolution architecture

8.2 Data Scientist (Utilisateur Expert)

- **Responsabilités :**
 - Analyse et interprétation des données
 - Développement modèles prédictifs
 - Validation métier des résultats
 - Feedback qualité données

8.3 Chercheurs (Utilisateurs Finaux)

- **Responsabilités :**

- Utilisation données pour recherches
- Remontée d'anomalies détectées
- Proposition nouveaux besoins
- Respect procédures d'accès

8.4 Responsable R&D (Sponsor Métier)

- **Responsabilités :**

- Validation orientations stratégiques
- Arbitrage priorités d'évolution
- Budget et ressources allouées
- Liaison direction TotalGreen

Contacts et Support

Support Technique : data-team@goodair.fr

DPO TotalGreen : dpo@totalgreen.fr

Urgences 24/7 : +33 1 XX XX XX XX

Historique des Versions

Version	Date	Modifications	Auteur
1.0	Jan 2025	Création document initial	Équipe Data
1.1	-	Ajout procédures RGPD	À venir

 **Document confidentiel - Usage interne TotalGreen/GoodAir uniquement**